

DOSSIER DE SOUTENANCE · RNCP37827BC01

PPMT

Plateforme Prédicative des Métiers en Tension Île-de-France

Collecte, stockage et mise à disposition des offres d'emploi France Travail et Adzuna

Claire Lucie DIOUF

Développeur en Intelligence Artificielle — Artefact

16 octobre 2026

Qui suis-je ?

Claire Lucie DIOUF

RH x Data

- 12 ans en ressources humaines : RH généraliste, SIRH / AMOA, GEPP et formation
- Executive Master Paris-Dauphine
- Consultante RH indépendante

Le marché du travail, je le vois tous les jours côté recrutement : PPMT le regarde côté données.

Mon rôle dans PPMT

En binôme avec Bernard GBOHOUGNON

Collecte France Travail (OAuth2, cascade), stockage, API, 57 tests

Et aussi

RGPD, modèle ML, dashboard Streamlit et son déploiement, dépôt Git (création et gestion)

Bernard : Adzuna, idempotence et journalisation du pipeline

4 embauches sur 10 jugées difficiles en Île-de-France, offres dispersées

41,7 %

des projets de recrutement jugés difficiles en Île-de-France (BMO 2025, France Travail)

62 435

offres franciliennes en base, 2 sources (Adzuna, France Travail)

235

métiers franciliens « très en tension » sur 1 514 (15,5 %)

PROBLÉMATIQUE

Comment collecter, fiabiliser et mettre à disposition, de façon automatisée, les offres d'emploi franciliennes de plusieurs sources afin d'identifier les métiers qui recrutent le plus et d'orienter candidats, recruteurs et organismes de formation ?

Pour qui : cabinets de recrutement · conseillers emploi · salariés en mobilité (CEP) · organismes de formation · développeurs

En Île-de-France : 41,7 % des 440 900 projets de recrutement jugés difficiles (BMO 2025, France Travail)

Une chaîne en une commande, de la collecte à l'API

6 W

POURQUOI

41,7 %

des projets de recrutement franciliens jugés difficiles ; offres dispersées

QUOI

62 435 offres

en base, via une chaîne automatisée ; 7 endpoints d'API

POUR QUI

5 profils

cabinets, conseillers emploi, salariés en mobilité (CEP), organismes de formation, développeurs

COMMENT

57 tests

pour 2 API (France Travail, Adzuna), Python, SQLite et FastAPI

QUAND

6 oct. 2026

date de collecte, relançable à la demande ; $\approx$ 35 s hors collecte

OÙ

Île-de-France

8 départements, de Paris à la grande couronne ; 2 sources

Objectif final

Rendre visibles, en un seul endroit, les métiers qui recrutent le plus en Île-de-France : 329 métiers au-dessus du seuil de tension (indice > 100), dont 235 très en tension, accessibles par une API sécurisée.

Quatre étapes automatisées transforment deux sources en une API



Notre méthode est un ETL : on extrait les offres (API), on les transforme en Python (pandas), puis on les charge dans SQLite. Une fois la base chargée, les indicateurs par métier, dont l'indice de tension, sont agrégés en SQL.

run_pipeline.py enchaîne **C1 → C4** · relançable à la demande (idempotent) · **57 tests pytest**

Python 3.11 · requests · pandas · SQLite · FastAPI · Pydantic · Streamlit

La cascade récupère 99,5 % des offres malgré un plafond de 3 150

C1 · Extract

Source	Type	Accès	Volume
France Travail — Offres v2	API REST	OAuth2	63 173 (sur 63 504)
Adzuna (agrégateur)	API REST	app_id + app_key	12 500 (sur 220 238)
Contours départements (IGN)	Fichier GeoJSON	HTTPS public	8 contours → base + carte
Communes d'Île-de-France	Fichier (GeoJSON → CSV)	HTTPS public	1 276 communes

Cascade France Travail (plafond 3 150)

département → fenêtres de dates → type de contrat
on coupe tant que le total dépasse 3 150
→ 63 173 offres sur 63 504 (99,5 %)

Au départ : FT 63 173 + Adzuna 12 500 = 75 673
→ 63 242 unifiées : FT 58 301 + Adzuna 4 941

Robustesse

- OAuth2 : jeton, 3 tentatives, HTTP 429
- 492 appels en ≈ 6 min 40
- Écart de 331 offres (0,5 %) avec le compteur
- Secrets dans .env, jamais dans le code

Six problèmes de qualité, six méthodes testées

C2 · Transform

Problème	Méthode retenue	Résultat
56 % de salaires non affichés	Médiane des salaires affichés : métier × dépt → métier → domaine → dépt → région	100 % complétés, valeurs repérées
Codes ROME absents (Adzuna)	Intitulé identique chez France Travail, sinon catégorie Adzuna (2 110 sans code)	636 intitulé · 1 388 catégorie
Lieux sans département	Référentiel des 1 276 communes d'Île-de-France (IGN / Insee)	32 offres restent sans département
Doublons	URL, puis empreinte MD5 de titre + entreprise + lieu, entre les 2 sources	12 404 supprimés · 0 en base
Contrats hétérogènes	7 catégories, temps de travail à part	Sources comparables
Coordonnées de recruteurs	Masquées [email] / [tel]	RGPD

Une règle = une fonction testée · 62 435 offres en base (France Travail 58 301 · Adzuna 4 134)

Indicateurs calculés sur les seuls salaires affichés · les 10 problèmes sont détaillés dans le dossier

Un indice, 1 514 métiers : 329 dépassent le seuil

C3 · Transform

store.py — 1 ligne par code ROME

```
WITH agg AS (  
  SELECT code_rome,  
    COUNT(*) AS nb_offres_total,  
    COUNT(DISTINCT entreprise),  
    AVG(contrat = 'CDI') * 100  
    -- + salaire médian (Python)  
  FROM offres GROUP BY code_rome)  
SELECT code_rome,  
  nb_offres_total * 100.0  
  / AVG(nb_offres_total) OVER ()  
  AS indice_tension  
FROM agg
```

Statuts selon l'indice :

< 50 saturé · 50 à 100 équilibré
100 à 150 en tension · > 150 très en tension

Indice de tension (ITM)

Offres du métier ÷ offres d'un métier moyen × 100.
Mesure la pression des employeurs, pas le ratio
offres / candidats.

Saturé · **1 006**

Équilibré · **179**

En tension · **94**


Très en tension · **235**

Restitution : Top 10 en tension

Les métiers sont classés par indice décroissant : les
10 premiers forment le Top 10 affiché dans la Vue
d'ensemble de Streamlit. L'API renvoie la même
liste triée (GET /metiers).

Les 235 métiers très en tension concentrent 75 % des offres

C3 · Résultats



Comment lire le graphique (Top 10 des métiers en tension)

Chiffre à droite de la barre, ex. 1 513 = indice de tension : 15 fois plus d'offres qu'un métier moyen (100).


Chiffre entre parenthèses, ex. (603 offres) = nombre d'offres de ce métier dans la base.

L'axe du bas reprend l'indice : plus la barre est longue, plus le métier est en tension.

Part des offres dans les métiers très en tension

par département d'Île-de-France (offres en base)


Nord ↑



Paris : le plus d'offres (13 445), mais la plus faible part très en tension (66 %). Ailleurs, 72 à 76 %.

Une base sans doublon garantit l'intégrité des données

C4 · Load



PK clé primaire : identifiant unique d'une ligne

FK clé étrangère : lien vers une autre table

UQ contrainte d'unicité : dédoublement

Pourquoi SQLite

Relationnel, sans serveur, un seul fichier .db

Intégrité

FK, CHECK, UNIQUE, 6 index

RGPD

Masquage des e-mails et téléphones, purge 12 mois, registre

Sept endpoints en lecture seule, protégés par une clé

C5 · Expose

GET	Accès	Rôle
/health	Public	Disponibilité, volumes
/offres	Clé	Filtres + pagination
/offres/{offre_id}	Clé	Détail d'une offre
/metiers	Clé	Tension, filtre statut
/metiers/{code_rome}	Clé	Fiche métier
/stats/departements	Clé	Densité, CDI, coordonnées
/stats/tension	Clé	Métiers par statut

Si l'API s'arrête

- Vérifier : /health (public) répond « ok » et 62 435 offres
- Relancer : une commande, uvicorn api.main:app
- Rien n'est perdu : la base est en lecture seule

Sécurité

- Clé requise (sauf /health) → 403
- Paramètres validés (Pydantic) → 422
- limit plafonné à 500 par page
- GET seul, sinon → 405
- Base ouverte en lecture seule
- SQL paramétré : pas d'injection
- Clé lue en variable d'environnement
- CORS limité au verbe GET
- HTTPS à prévoir au déploiement

Avec la clé, les données ; sans clé, un refus (403)

C5 · Expose

127.0.0.1:8000/docs

API PPMT — Métiers en tension Île-de-France 2.0.0 OAS 3.1

[/openapi.json](#)

Offres d'emploi France Travail + Adzuna (8 départements franciliens) et indicateurs de tension par code ROME. Authentification : en-tête `X-API-Key`.

Authorize

Service

GET /health Disponibilité du service (public)

Offres

GET /offres Liste paginée et filtrable des offres

GET /offres/{offre_id} Détail d'une offre

Tension

GET /metiers Indicateurs de tension par métier (tri décroissant)

GET /metiers/{code_rome} Fiche métier : tension, départements, contrats

Statistiques

GET /stats/departements Volume d'offres, densité, part de CDI, salaire médian et coordonnées par département

GET /stats/tension Répartition des métiers par statut de tension

```
# public
$ curl /health
{"status":"ok", "nb_offres":62435}
```

```
# sans clé
$ curl /metiers
HTTP 403 Clé API invalide
```

```
# avec clé
$ curl /offres?departement=13
HTTP 422 motif ^(75|77|...|95)$
```

```
# avec clé
$ curl /metiers/K1304
{"indice_tension": 3842.4,
 "statut": "TRES EN TENSION",
 "salaire_median": 22477}
```

57 tests protègent chaque étape de la chaîne

4

C1 collecte

API simulées : arrêt à la dernière page, plafond de 3 150 offres, reprise après un refus 429

31

C2 / C3 règles

Salaires, codes ROME, communes, contrats, doublons ; e-mails et téléphones masqués

13

C4 base


Zéro doublon, liens valides, périmètre IDF, aucun e-mail ni téléphone en clair

9

C5 API


Clé exigée (403), valeur invalide (422), inconnu (404), lecture seule (405), filtres, pagination

422 : valeur refusée



13 = Bouches-du-Rhône, hors Île-de-France : la requête est rejetée, pas traitée.

Indice moyen = 100



Indice = offres du métier ÷ offres d'un métier moyen × 100
Test : la moyenne des 1 514 indices vaut 100.

57 / 57

tests réussis

en 10 secondes

pytest tests/ -v

Le profil des offres permet de repérer les métiers en tension

Hors BC01

CIBLE ET VARIABLES

ITM > 100

46 % des 717 métiers sont en tension

Aucune variable de volume n'est donnée au modèle : l'ITM étant calculé à partir des nombres d'offres, il retrouverait sinon la formule.

Variables utilisées : part de CDI, CDD et intérim · salaire et part de salaires non affichés · expérience demandée · longueur des descriptions · famille ROME

CLASSIFICATION D'APRÈS LE PROFIL

717 métiers ≥ 10 offres · validation croisée à 5 plis · ROC-AUC (hasard : 0,51)



La longueur des descriptions pèse le plus mais reflète surtout la source (300 ou 500 caractères). Sans elle : 0,80, un signal réel mais modeste.

Régression logistique : modèle linéaire, ne capte pas les combinaisons.

Random Forest : ensemble d'arbres, capte les relations non linéaires.

XGBoost : corrige ses erreurs arbre après arbre ; F1 0,79, retenu.

Une chaîne complète et testée, prête à s'étendre

62 435

offres en base

4

sources, 2 API

7

endpoints API

57

tests réussis

≈ 35 s

pipeline hors collecte

Perspectives

Offre / demande

Demandeurs d'emploi par code ROME → vrai ratio de tension

Historisation

Instantanés quotidiens → prévision à 3 mois

Déploiement

API sur Cloud Run · dashboard déjà en ligne en secours

Passage à l'échelle

Autres régions · planification Airflow

Limites assumées : une seule collecte (6 octobre 2026) · Adzuna lu en échantillon · collecte non planifiée · l'indice ne mesure que la demande des employeurs

Merci de votre attention